

HW 1 Marshen S Lia

S - сторона изображения

B - размер батча

Слой	Размер батча на входе слоя	FLOPS
Conv 8x8 3 → 32	$32 \left(\frac{S}{2}\right)^2 = 8S^2$	$2 \cdot B \cdot 8S^2 \cdot 3 \cdot 8^2 = 2352BS^2$
Conv 5x5 32 → 64	$64 \left(\frac{S}{4}\right)^2 = 4S^2$	$2B \cdot 4S^2 \cdot 32 \cdot 5^2 = 6400BS^2$
Conv 3x3 64 → 128	$128 \left(\frac{S}{8}\right)^2 = 2S^2$	$2B \cdot 2S^2 \cdot 64 \cdot 3^2 = 2304BS^2$
Conv 1x1 128 → 256	$256 \left(\frac{S}{8}\right)^2 = 4S^2$	$2B \cdot 4S^2 \cdot 128 = 1024BS^2$
Conv 3x3 256 → 256	$256 \left(\frac{S}{16}\right)^2 = S^2$	$2B \cdot S^2 \cdot 256 \cdot 3^2 = 4608BS^2$
Conv 1x1 256 → 512	$512 \left(\frac{S}{16}\right)^2 = 2S^2$	$2B \cdot 2S^2 \cdot 256 = 1024BS^2$
Linear 512 → 256	256B	$B(2 \cdot 512 \cdot 256 + 256) = 262400B$
Linear 256 → 100	100B	$B(2 \cdot 256 \cdot 100 + 100) = 51300B$

Сумма свертки = $17712BS^2$

Relu учитывается 0

Сумма линейных = $313700B$

Сумма BN = $42BS^2$, AvgPool = $2BS^2$

Итого: $FLOPS(S, B) = 17756BS^2 + 313700B$

С учетом Relu и Max Pool

Итого: $FLOPS(S, B) = 17783BS^2 + 313700B$

Пиковое потребление.

$M = \text{Elements} \cdot Q$ где $Q = 4$ байта $X = 3S^2$ $P = 104032$

Максимум достигается после первой свертки и BN, тогда $3S^2 + 8S^2 + 2S^2 = 13S^2$ (батч после свертки)

Memory = $\frac{1}{P} + 13BS^2 \approx 4 \text{ мб} + 76BS^2 + \text{символы}$

Передаваемые байты

Считаем для каждого одно чтение и запись

$$F_i = f_{x_i} X + f_{b_i} B, \quad M_i = 4(m_{x_i} X + m_{b_i} B + p_i) \text{ байт}$$

Для conv2d: 3x прочитано + 8x записано + 4704 веса; $M = 4(11x + 4704)$

BN: 8x прочитано + 8x записано + 32 · 4; $M = 4(16x + 128)$

Суммарно по 23 операциям: $M(S, B) = 4(10453/6 + B(133S^2 + 2148))$ байт

Latency

Пусть $\Theta_L = (t_0, r_F, r_m)$, t_0 — эвристическое время запуска kernel
 r_F — скорость вычисления, r_m — пропускная способность

$$L = \sum_{i=1}^{(B, S, \Theta_L)_{23}} \max\left(t_0, \frac{F_i(S, B)}{r_F}, \frac{M_i(S, B)}{r_m}\right), \text{ где } M_i(S, B) \text{ и } F_i(S, B) \text{ берется}$$

из расчета выше

Энергия

P_0 — потребление в ваттах (статическое)

e_F — потребление фл/флор, e_m — потреб. гтс/байт

$\Theta_E = (P_0, e_F, e_m, \Theta_L)$, тогда

$$E(S, B, \Theta_E) = P_0 L(B, S, \Theta_L) + e_F \cdot \text{FLOPS} + e_m \cdot M$$