ZerO Initialization: Initializing Neural Networks with only Zeros and Ones

Разбор статьи

Студент: Маршев Илья Сергеевич

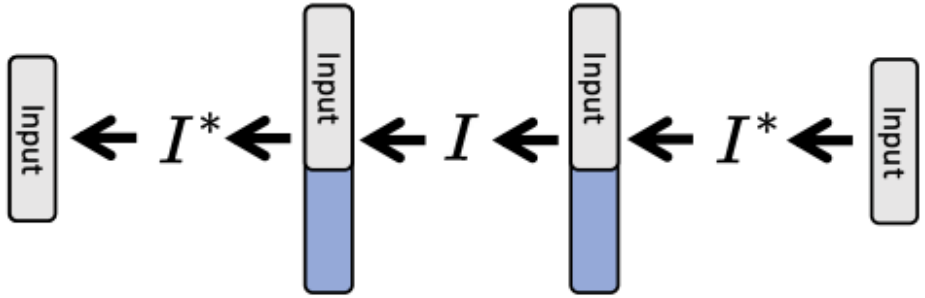
Jiawei Zhao, Florian Schäfer, Anima Anandkumar

Для чего нужна хорошая инициализация

- Начальные веса влияют на распространение активаций и градиентов
- Слишком маленький масштаб весов может привести к затухающим градиентам, слишком большой – к взрывам
- Популярные методы Kaiming и Xavier выбирают веса случайным способом

Почему недостаточно identity initialization

Единичная матрица сохраняет входной сигнал, но при расширении слоя простое дополнение нулями ограничивает разнообразие признаков

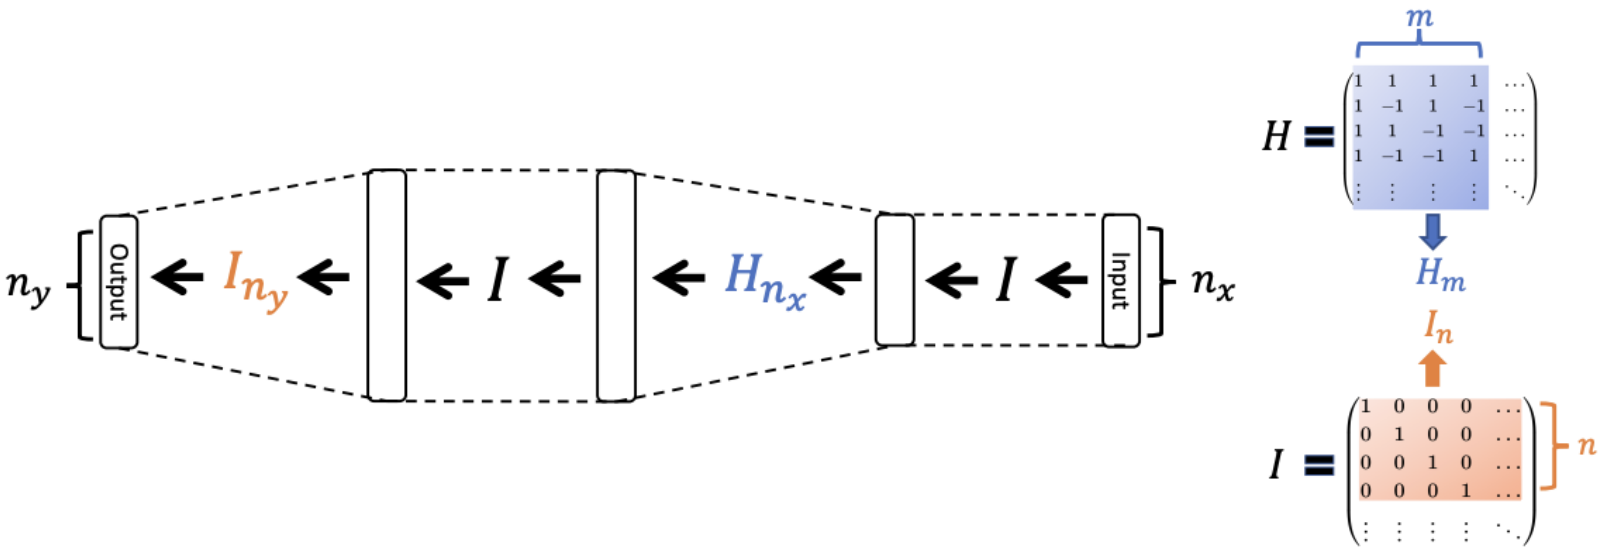


$$(x_1, x_2) \to (x_1, x_2, 0, 0)$$

При расширении слоя **partial identity** дополняет вход нулями. Дополнительные координаты остаются **неиспользованными**, поэтому увеличение ширины не даёт ожидаемой выразительности

- Новые координаты изначально не получают сигнал.
- В рассмотренной авторами постановке возникает ограничение размерности активаций

Идея ZerO: identity + Hadamard



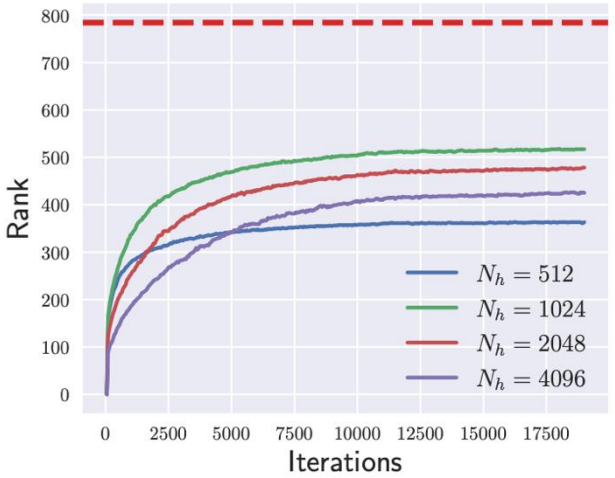
Авторы предлагают **детерминированную инициализацию ZerO**, которая устраняет всякую случайность при инициализации веса.

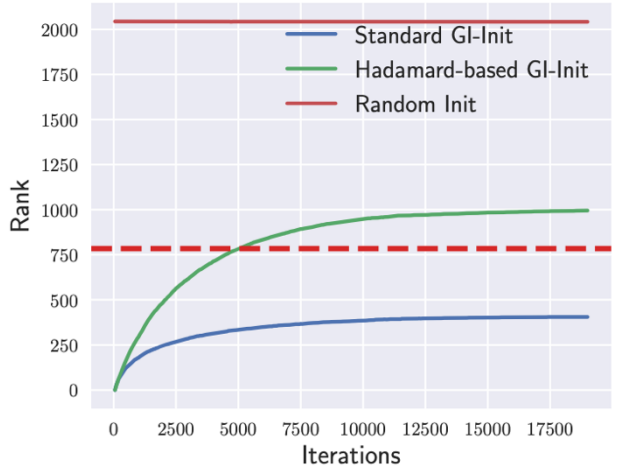
Как показано на рисунке 1, нулевая инициализация сетей с помощью преобразований Адамара и идентичности, которые присваивают всем весам только нули и единицы

Почему Hadamard помогает: ограничение ранга

- Рассматривается сеть с ReLU, где скрытые слои шире входа: $n_h > n_x$
- Обозначим отклонение весов от identity как $W_l' = W_l - I$

Инициализация	**Результат теоремы**
Identity + случайное возмущение	W_l' имеет полный ранг почти наверное
Partial identity на входе и выходе	Размерность пространства активаций и ранг W_l' ограничены n_x на протяжении обучения
Hadamard на входе	Пространство активаций может иметь размерность больше n_x, снимая это ограничение





эксперимент на **трёхслойной сети и MNIST**
Hadamard позволяет выйти за ограничение обычной identity initialization

ZerO реализация

Algorithm 1 *ZerO Initialization.*

Input: a neural network $\mathcal{F}$ with L matrices $\boldsymbol{W}_l \in \mathbb{R}^{P_l \times Q_l}$ for l in $1, ..., L$. $\boldsymbol{I}^*$ is partial identity matrix defined in Definition 1. $\boldsymbol{H}_m$ is the Hadamard matrix defined in Definition 2.

For l **in** $1, ..., L$**:**

If $P_l = Q_l$**:** $\boldsymbol{W}_l \leftarrow \boldsymbol{I}$ ▷ Identity mapping

If $P_l < Q_l$**:** $\boldsymbol{W}_l \leftarrow \boldsymbol{I}^*$ ▷ Propagate the first P_l dimensions

If $P_l > Q_l$**:** $\boldsymbol{W}_l \leftarrow c\,\boldsymbol{I}^*\boldsymbol{H}_m\boldsymbol{I}^*$, where $m = \lceil \log_2(P_l) \rceil$ and $c = 2^{-(m-1)/2}$ ▷ Apply Hadamard matrix

ZerO инициализирует только слои, увеличивающие размерность, с помощью матриц Адамара, чтобы избежать вырождения при обучении.

Мы применяем ZerO к свёртке аналогичным образом, учитывая изменение размеров каналов. Когда K — это свертка 1x1, K также можно представить в виде матрицы cout × cin, что соответствует инициализации в алгоритме 1

Algorithm 2 *ZerO Initialization on Convolution.*

Input: number of input channels c_{in}, number of output channels c_{out}, odd kernel size k.

Return: a $c_{out} \times c_{in} \times k \times k$ convolutional kernel $\boldsymbol{K}$.

Let $n \leftarrow \lfloor k/2 \rfloor$

If $c_{out} = c_{in}$**:** $\boldsymbol{K}[:, :, n, n] \leftarrow \boldsymbol{I}$

If $c_{out} < c_{in}$**:** $\boldsymbol{K}[:, :, n, n] \leftarrow \boldsymbol{I}^*$

If $c_{out} > c_{in}$**:** $\boldsymbol{K}[:, :, n, n] \leftarrow c\,\boldsymbol{I}^*\boldsymbol{H}_m\boldsymbol{I}^*$, where $m = \lceil \log_2(P_l) \rceil$ and $c = 2^{-(m-1)/2}$

Экспериментальная установка

Параметр	**Основной эксперимент**
Модель	ResNet-18, ResNet-50
Данные	CIFAR-10
Сравнение	ZerO, Kaiming, Xavier
Повторения	10 запусков
Learning rate	0.1
Momentum	0.9
Weight decay	10^{-4}
Warmup	10 эпох

Параметр	**Значение**
Модель	ResNet-50
Датасет	ImageNet
Инициализации	ZerO, Kaiming, Xavier
Повторения	10 запусков с разными seed
Learning rate	0,1
Momentum	0,9
Weight decay	0,0001
Warmup	5 эпох
Метрика	Test error, % — среднее ± стандартное отклонение

Полученные результаты в статье

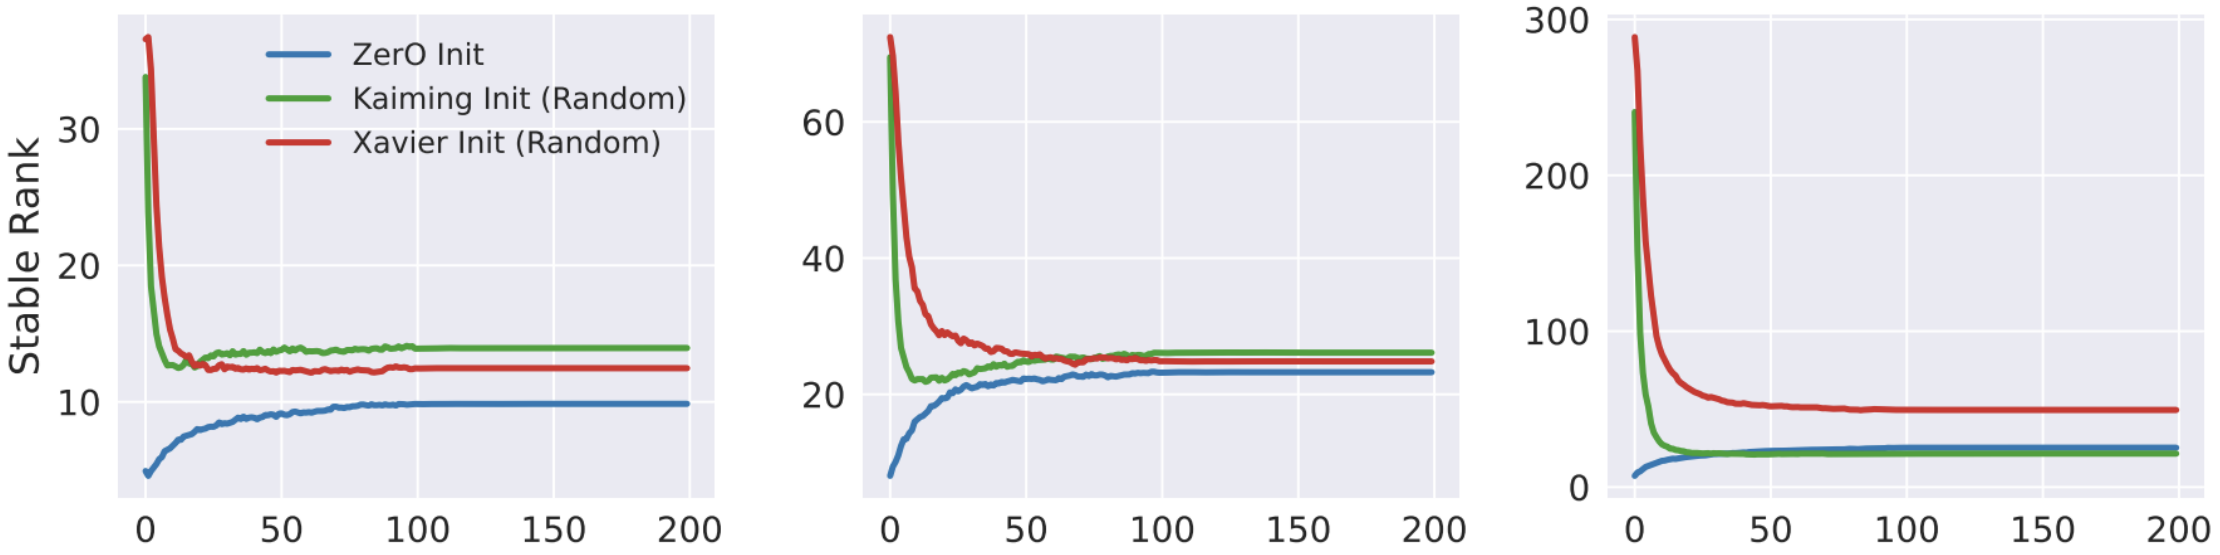
Dataset	**Model**	**Initialization**	**Test Error** (mean ± std)
CIFAR-10	ResNet-18	**ZerO Init**	5.13 ± 0.08
		Kaiming Init	5.15 ± 0.13
		Xavier Init	5.23 ± 0.16
ImageNet	ResNet-50	**ZerO Init**	23.43 ± 0.04
		Kaiming Init	23.46 ± 0.07
		Xavier Init	23.65 ± 0.11

Method	**ZerO**	**ReZero**	**Fixup**	**SkipInit**	**ConstNet**	**ConstNet***
ResNet-18	5.13	5.20	5.17	5.26	72.39	5.41
ResNet-50	4.53	4.72	4.51	4.63	71.58	4.88

Изменение сложности весов при обучении

$$\text{stable rank}(W) = \frac{\sum_i \sigma_i^2}{\sigma_{\max}^2}$$

показывает, насколько энергия матрицы распределена между сингулярными направлениями.



Выводы

Случайные начальные веса не обязательны для успешного обучения рассмотренных сетей

- ZerO сочетает детерминированную инициализацию с сопоставимым качеством.
- Интерес представляет не только accuracy, но и структура весов после обучения.
- Метод требует корректной реализации residual-ветвей и warmup.
- Результаты на ResNet-18 не доказывают универсальность для всех архитектур.
- Детерминированная инициализация не делает весь процесс обучения детерминированным.