Отчёт о воспроизведении результатов статьи

ZerO Initialization: Initializing Neural Networks with only Zeros and Ones
Илья Маршев · 10 октября 2026 года
Эксперименты: MLP / MNIST и ResNet-18 / CIFAR-10.

1. Цель и основной результат

Статья [1] предлагает детерминированную инициализацию: единичные и частичные единичные матрицы для сохраняющих и уменьшающих размерность слоёв, преобразование Hadamard для расширяющих слоёв. В ResNet последняя свёртка residual-ветви обнуляется. Проверялись ограничение ранга и его преодоление на MNIST (Figure 3), точность на CIFAR-10 (Table 2), динамика рангов (Figure 5), устойчивость к сжатию (Figure 6) и влияние warmup (Figure 8).

На MNIST качественный эффект Figure 3 получен: partial identity сохраняет ранг ниже размерности входа, ZerO преодолевает эту границу. **На CIFAR-10 основной результат о сопоставимой точности ZerO не получен:** ошибка 13,29% против 5,13% в статье. Kaiming и Xavier дают близкое к статье качество. Преимущества ZerO при pruning и Tucker-2 не воспроизведены.

2. Протокол и достоверность сравнения

Использована статья arXiv:2110.12661v3 и официальный репозиторий [2]. В опубликованном коде есть MNIST-пример, но нет CIFAR ResNet и compression-экспериментов; точные настройки последних частично реконструированы. Допущения и отличия от статьи перечислены ниже; параметры запусков сохранены вместе с результатами.

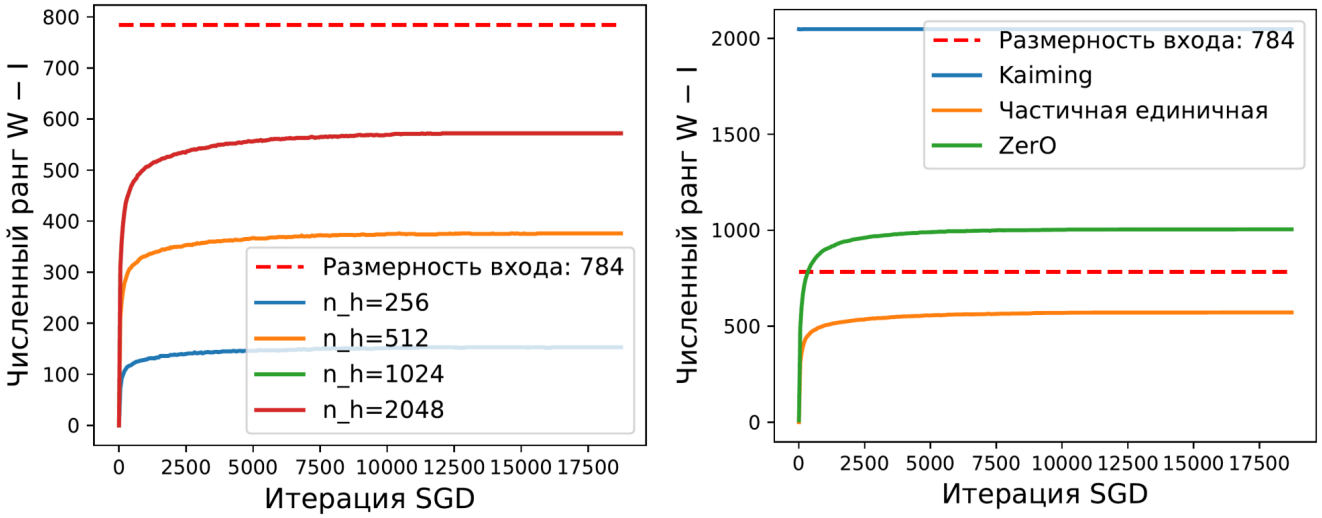
Настройка	MNIST	CIFAR-10
Модель	MLP: 784 → 784 → n_h → n_h → 10; ReLU, без bias	CIFAR ResNet-18: stem 3×3, без maxpool; [2,2,2,2], 11 173 962 параметра
Данные	60 000 train / 10 000 test; ToTensor	50 000 train / 10 000 test; crop, flip, нормализация
Обучение	20 эпох, batch 64, SGD LR 0,1; без momentum/weight decay	200 эпох, batch 128, SGD LR 0,1, momentum 0,9, weight decay 0,0001
Расписание	StepLR: ×0,7 после 12 эпох	Warmup 10 эпох от 0,01, затем cosine
Повторы	Семь запусков; обучение сбрасывает seed на 1	Один seed 0 для каждого из трёх методов
Измерение ранга	Numerical rank(W − I), порог 1e−4	Stable rank полного ядра, матрица [Cout, Cin·kH·kW]

Применён множитель **sqrt(2/N)** из Algorithm 1 статьи; официальный MNIST-пример использует **1/sqrt(N)**. Различие зафиксировано, а не скрыто. В MNIST случайная модель создавалась до сброса seed внутри обучения, поэтому её начальная инициализация не гарантированно определяется seed=1. Новый запуск через run_mnist.py фиксирует seed до создания модели.

Итоговые CIFAR-метрики взяты из runs/summary.csv; compression и градиенты — из CSV/metadata. MNIST test history извлечена из выводов выполненного mlp_ZeRO.ipynb: 140 оценок, по 20 на каждый запуск. Сырые траектории ранга и checkpoints MNIST не сохранены; Figure 3 включена из оригинальных PDF. Для CIFAR также отсутствуют history.csv, ranks.csv и checkpoints: Figure 5 и кривые обучения доступны как серверные изображения. Из графиков не восстанавливались искусственные численные истории.

3. MNIST: Figure 3

В теореме 1 ограничивается ранг остаточной компоненты **W′ = W − I**: при partial identity он не превышает входную размерность **n_x = 784**. Hadamard меняет ориентацию подпространства активаций и позволяет преодолеть ограничение. Здесь измеряется численный ранг l3.weight − I, а не дробный stable rank.



Левая панель. Все кривые остаются ниже 784. Для n_h=1024 и 2048 траектории визуально совпадают и выходят примерно на 570. Для n_h=256 и 512 граница 784 тривиальна, поскольку ранг не может превышать ширину самой матрицы. Наиболее содержательна проверка расширяющих слоёв с шириной больше 784.

Правая панель. При n_h=2048 partial identity остаётся ниже 784; ZerO пересекает эту границу и достигает примерно 1000; Kaiming имеет почти максимальный ранг около 2048. Эти значения описывают изображение приблизительно, а не заменяют отсутствующий rank CSV. Порядок кривых и преодоление ограничения ZerO согласуются с Figure 3 статьи.

Метод / ширина	Итоговая test accuracy	Итоговая NLL
Partial identity, 256	98,38%	0,0699
Partial identity, 512	98,34%	0,0678
Partial identity, 1024	98,34%	0,0662
Partial identity, 2048, левая панель	98,34%	0,0662
Kaiming, 2048	98,28%	0,0664
Partial identity, 2048, правая панель	98,34%	0,0662
ZerO, 2048	98,38%	0,0653

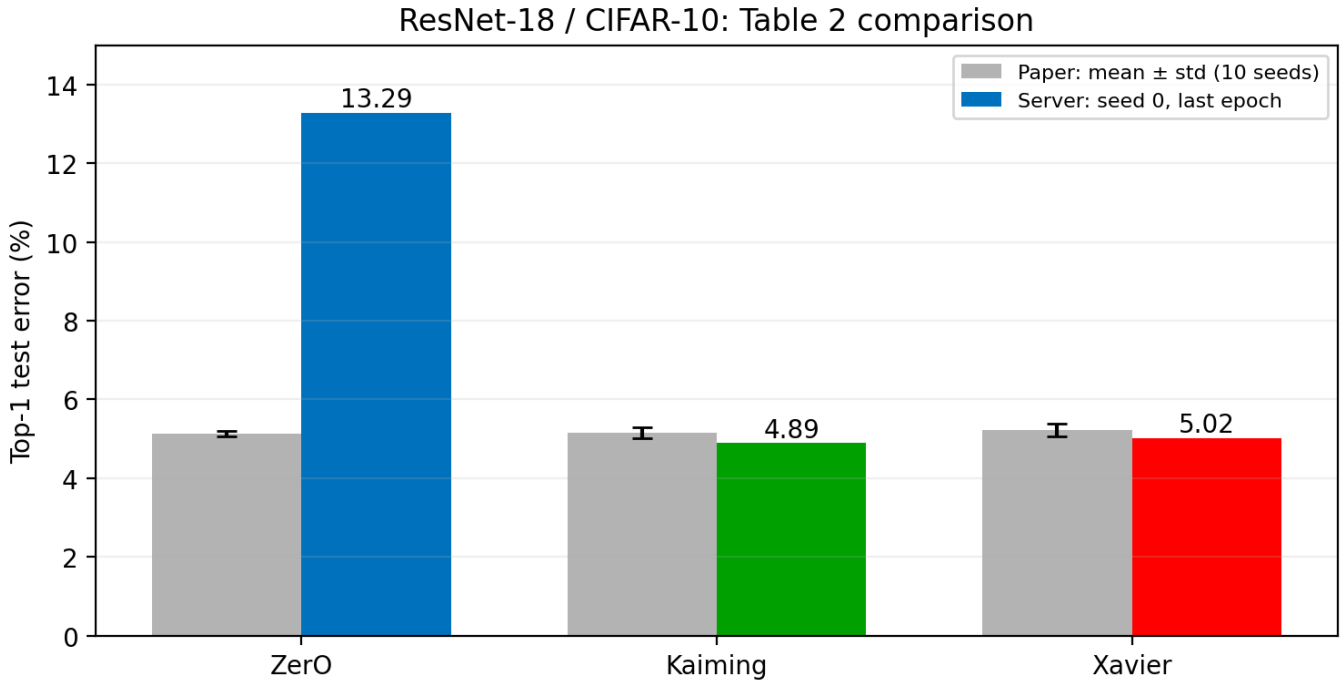
Граница воспроизведения: в Figure 3 статьи сеть содержит три матрицы, здесь четыре; набор ширин статьи — 512/1024/2048/4096, здесь — 256/512/1024/2048. Appendix B описывает 14 эпох, здесь 20. Поэтому подтверждён качественный механизм, но не точное совпадение чисел и траекторий. Accuracy выше 98% согласуется с MNIST-результатами Appendix B; разница 0,10 п.п. между ZerO и Kaiming без повторов не доказывает превосходства ZerO. Figure 7 с распределениями весов не воспроизводилась.

4. CIFAR-10: точность и динамика ранга

Table 2: точность

Основной результат — последняя, 200-я эпоха на полном test set. Опубликованные значения являются средним и стандартным отклонением по десяти запускам; у нас по одному seed, поэтому собственные std и доверительные интервалы не определены.

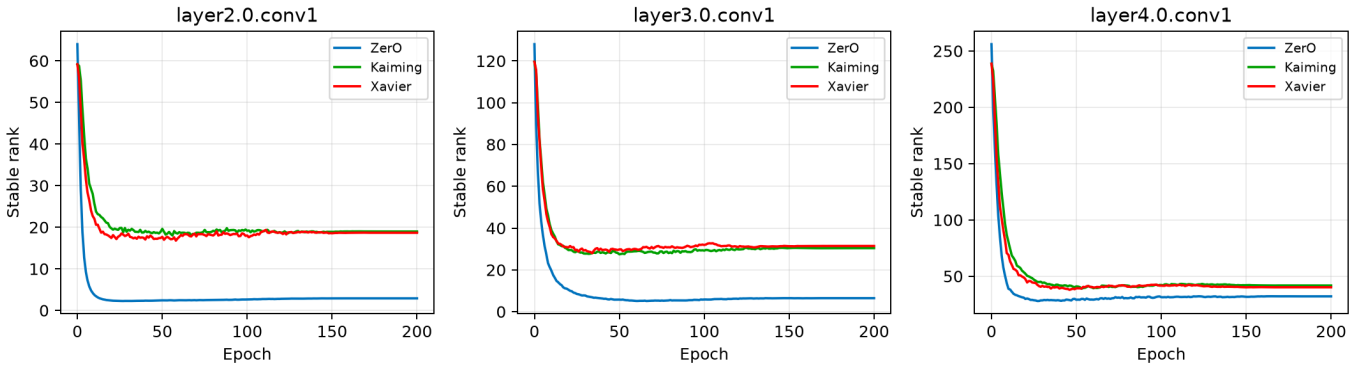
Метод	Test error статьи	Наш test error	Отклонение, п.п.	Наша accuracy
ZerO	5,13 ± 0,08%	13,29%	+8,16	86,71%
Kaiming	5,15 ± 0,13%	4,89%	−0,26	95,11%
Xavier	5,23 ± 0,16%	5,02%	−0,21	94,98%



Kaiming/Xavier находятся в том же диапазоне качества, что и статья. ZerO уступает им на 8,40 и 8,27 п.п. ошибки. Выбор лучшей наблюдавшейся test эпохи не устраняет расхождение: лучшая accuracy ZerO составляет 86,91%. Из запланированных 30 полных запусков завершены три; воспроизводимость и меньший межзапусковый разброс ZerO не проверены.

Figure 5: stable rank

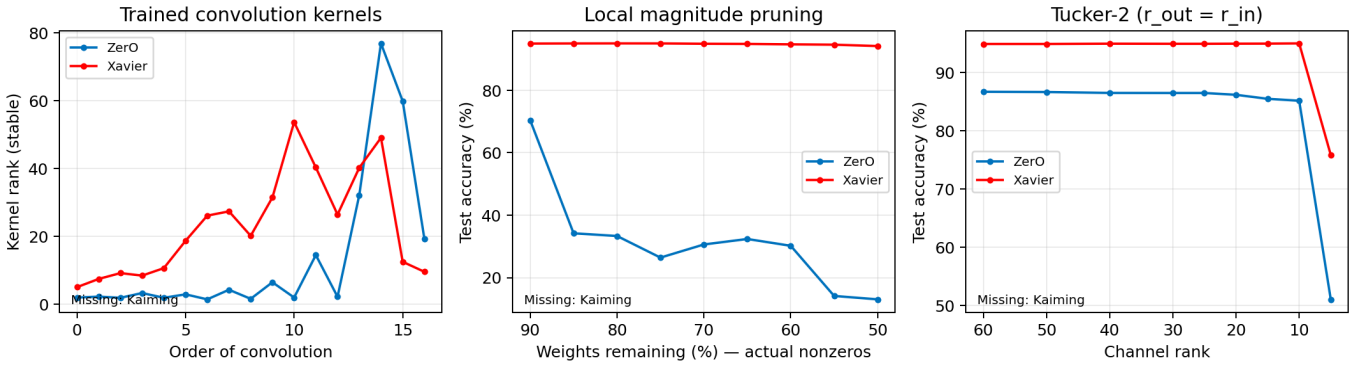
Stable rank вычисляется как **srank(W) = ||W||²_F / ||W||²_2 = Σσ²_i / σ²_max**; для нулевого ядра условно принимается 0. Выбраны layer2.0.conv1, layer3.0.conv1, layer4.0.conv1; identity не вычитается, развёртка ядра фиксирована до эксперимента.



В статье ZerO демонстрирует возрастающую низкоранговую траекторию. Здесь выбранные ядра начинают с высоких рангов и быстро уменьшают их; на поздних эпохах заметен лишь небольшой рост. Проверка нашей инициализации даёт стартовые ранги 64/128/256. **Ожидаемая форма Figure 5 не воспроизведена.** Возможные различия — выбор авторских слоёв и измеряемого объекта; без исходного CIFAR-кода и сырых историй точное соответствие проверить нельзя. Меньший конечный ранг сам по себе не доказывает greedy low-rank learning.

5. CIFAR-10: Figure 6 и сжатие

Все три панели восстановлены из CSV для ZerO/Xavier. Kaiming compression отсутствует. Каждая точка начинается с исходного checkpoint; fine-tuning и пересчёт BN statistics не выполнялись. Все оценки используют 10 000 test images; baseline совпадает с итоговыми training metrics.



Ранги ядер. Измерены stem и 16 residual Conv без projection shortcuts. В 14 из 17 ядер stable rank ZerO ниже Xavier; средние — 13,79 против 23,29. Однако некоторые поздние ядра имеют больший ранг у ZerO. Это частично согласуется с меньшей сложностью весов в статье, но модели имеют разную accuracy. Численный алгоритм левой панели авторов отдельно не опубликован; здесь выбран stable rank по §5 статьи.

Pruning. Наименьшие по модулю веса удаляются внутри каждого Conv/Linear, включая projections и classifier; BN/bias сохраняются. По оси X показана фактическая доля оставшихся ненулевых весов.

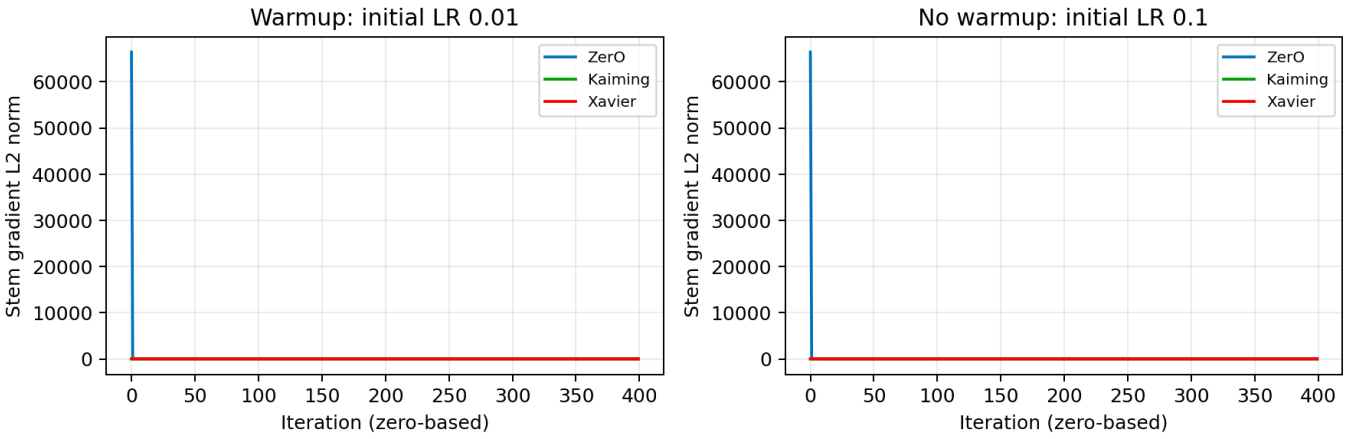
Сжатие	ZerO accuracy	Xavier accuracy
Без сжатия	86,71%	94,98%
Pruning: осталось 90% весов	70,42%	94,95%
Pruning: осталось 50% весов	13,05%	94,16%
Tucker-2: r_out=r_in=10	85,19%	95,05%
Tucker-2: r_out=r_in=5	51,04%	75,87%

Tucker-2. Сжимается layer4.1.conv2, Conv 512→512: HOSVD и пять HOOI-итераций, реальная замена на 1×1 → 3×3 → 1×1. Выбор конкретного слоя и равных канальных рангов — наш протокол, не подтверждённый авторским кодом. Полноранговая проверка 512/512 прошла: относительная ошибка выхода 2,02e−6 для ZerO и 2,10e−6 для Xavier. При r=10 модель содержит на 21,01% меньше параметров и на 6,76% меньше Conv/Linear MACs; ускорение inference не измерялось.

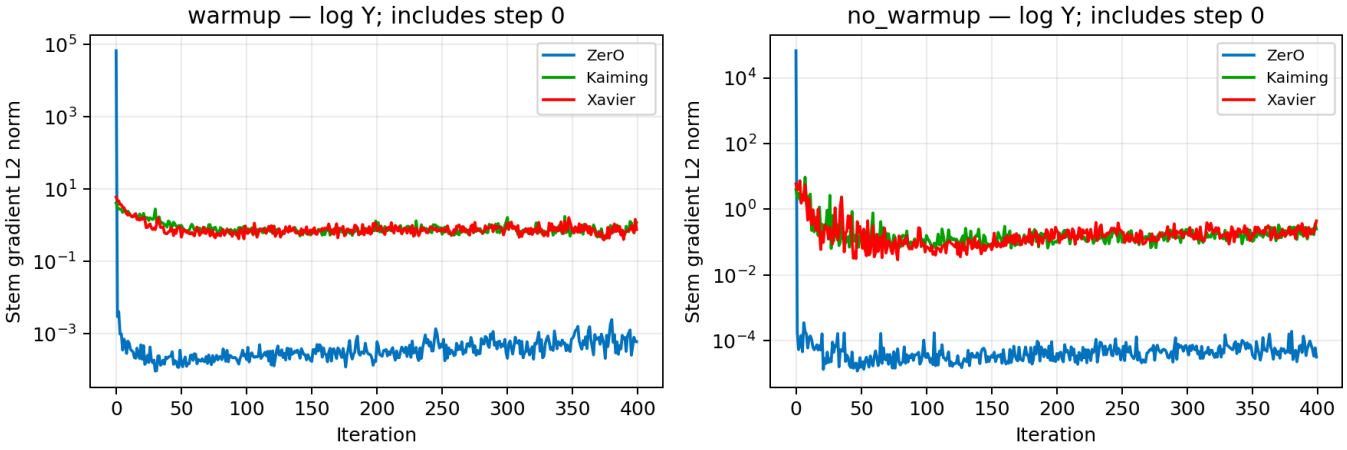
Статья сообщает об улучшении sparsity и допустимого низкого ранга без потери качества. **В наших данных преимущество ZerO не получено даже относительно собственного baseline:** pruning половины весов снижает accuracy ZerO на 73,66 п.п., Xavier — на 0,82; Tucker r=5 снижает её на 35,67 и 19,11 п.п. соответственно.

6. Figure 8: warmup и градиенты

Завершены шесть запусков по 400 шагов. Измеряется L2/Frobenius норма градиента conv1.weight после backward и до optimizer step, без clipping и AMP. Хеши augmented batches совпадают между всеми шестью запусками на каждом шаге. Warmup начинается с LR 0,01, режим без warmup — с 0,1.



Первый gradient ZerO равен **66 448,24** в обоих режимах, Kaiming — 4,05, Xavier — 5,94. Совпадение первого gradient ожидаемо: LR ещё не повлиял на параметры. Из-за выброса полная линейная шкала скрывает дальнейшую динамику; ниже показаны те же данные с логарифмической осью Y, без удаления шага 0.



Медианы нормы на шагах 1–399: ZerO — 0,000323 с warmup и 0,0000415 без него; Kaiming — 0,736 и 0,147; Xavier — 0,721 и 0,151. **Масштаб и количественная картина Figure 8 статьи не воспроизведены.** Random gradients также заметно различаются между режимами.

Приближённая норма первого SGD-обновления ZerO составляет 664,48 с warmup и 6644,82 без него, тогда как исходная норма stem около 2,45. Это гипотеза о проблеме ранней динамики, а не доказанная причина плохой final accuracy. Для проверки нужны ранние checkpoints, нормы весов и статистики BN.

7. Итоги, ограничения и воспроизводимость

Результат статьи	Что получено
Figure 3: ограничение partial identity и его преодоление ZerO	Качественно подтверждено на MNIST; протокол отличается
Точность Kaiming/Xavier на CIFAR-10	Близка к статье в одном seed
Точность и меньший разброс ZerO	Точность не получена; разброс не проверен
Figure 5: возрастающая низкоранговая траектория	Ожидаемая форма не получена
Figure 6: низкие ранги и лучшая устойчивость к сжатию	Ранги частично ниже; преимущество при сжатии не получено
Figure 8: влияние warmup	Измерения выполнены; масштабы и форма расходятся

CIFAR-измерения выполнены на NVIDIA H100 80GB, FP32, PyTorch 2.8.0+cu128, deterministic mode, без TF32. Три запуска заняли суммарно 99,95 мин обучающих проходов, 8,61 мин test и 1,41 мин анализа рангов; около 109,97 мин без checkpoint I/O. Peak CUDA allocated — 1272,50 MiB. Шесть Figure 8 запусков заняли 66,24 с. Время MNIST и отдельный compression wall-clock не сохранены.

Проект подтверждает механизм преодоления ограничения ранга на MNIST, но не все практические преимущества ZerO на CIFAR-10. Расхождения нельзя уверенно приписать одной причине: остаются различия архитектуры, нормировки Hadamard, BN, preprocessing и расписания, а также нехватка повторов. Следующие проверки — перенос сырых историй/checkpoints, диагностика первого gradient, compression Kaiming и оставшиеся seeds. Table 3, Figure 4, Figure 7, ResNet-50 и Transformer не воспроизводились.

Обучение реализовано в zero_experiments/, запускается через run_zero.py и run_mnist.py; notebooks читают результаты. Запуск из каталога hw2/reproduction:

```
python run_zero.py seeds --config configs/main.json --device cuda --root runs/cifar-new
python run_mnist.py --method ZerO --width 2048 --root runs/mnist-new
```

Численные источники: runs/summary.csv, runs/compression/, runs/figure8/, runs/mnist/test_history.csv. Сведения о происхождении MNIST: runs/mnist/metadata.json. PDF-панели MNIST сохранены в runs/mnist/figures/figure_3_left.pdf и figure_3_right.pdf.

[1] Zhao J., Schäfer F., Anandkumar A. **ZerO Initialization: Initializing Neural Networks with only Zeros and Ones**. TMLR, 2022. arXiv:2110.12661v3, Definitions 1–2, Theorem 1, Algorithm 1, Figures 3/5/6/8, Table 2 и Appendix B/C.

[2] Официальный код ZerO, commit cf2bf5d7d967958b3bb232755b288d97239896a8. Формулы и ссылки на исходную статью приведены также в notebook MLP.